


NEURIPS 2017

Attention Is All You Need


Vaswani · Shazeer · Parmar · Uszkoreit · Jones · Gomez · Kaiser · Polosukhin

Google Brain · Google Research · University of Toronto



Les limites des RNN & LSTM

chemin d'information = $O(n)$




RÉCURRENCE : CHAQUE ÉTAT ATTEND LE PRÉCÉDENT

Calcul **séquentiel** : h_t attend h_{t-1} · le signal se **dilue** avec la distance.

Le traitement séquentiel


Récurrent

4 sauts



Self-attention

1 saut



TOUTE PAIRE DE MOTS : CONNEXION DIRECTE

*Récurrent : le chemin d'information croît en $O(n)$ · Self-attention : **un saut**, toujours.*

Rompre avec la récurrence

TYPE DE COUCHE	OP. SÉQUENTIELLES	CHEMIN MAX
Récurrent	$O(n)$	$O(n)$
Convolution	$O(1)$	$O(\log_k n)$
Self-attention	$O(1)$	$O(1)$


n = longueur de séquence · k = largeur du noyau · source : Vaswani et al. 2017, table 1.

PARTIE 1

L'architecture

Encodeur, décodeur, et le mécanisme qui remplace la récurrence


Encodeur & Décodeur



$N = 6$ couches de chaque côté · $d_{model} = 512$ · $d_{ff} = 2048$.


La connexion résiduelle

$\text{LayerNorm}(x + \text{Sublayer}(x))$



$\text{LayerNorm}(x + \text{Sublayer}(x))$: le signal d'origine circule **sans obstacle**.

Query, Key, Value



*Trois projections apprises : chaque mot devient une **Query**, une **Key** et une **Value**.*

La formule de l'attention

$$\text{Attention}(\textcolor{teal}{Q}, \textcolor{teal}{K}, \textcolor{red}{V}) = \text{softmax}\left(\frac{\textcolor{teal}{Q} \textcolor{teal}{K}^\top}{\sqrt{d_k}}\right) \textcolor{red}{V}$$


$\textcolor{teal}{Q} \cdot \textcolor{teal}{K}^\top$: similarité des paires

softmax : poids qui somment à 1

$\textcolor{red}{V}$: mélange des valeurs


softmax ligne par ligne : chaque sortie est un **mélange pondéré** de toute la séquence.

Scaled dot-product



Sans l'échelle $1/\sqrt{d_k}$, le softmax sature et les gradients s'évanouissent.

Multi-head attention




$h = 8$ têtes en parallèle · $d_k = d_v = 64$ · chaque tête apprend un sous-espace.

Positional encoding

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

DIMENSIONS À FRÉQUENCES CROISSANTES



Longueurs d'onde en **progression géométrique** : l'ordre devient un signal.


PARTIE 3

Résultats

WMT 2014 · BLEU 28.4 & 41.8 · un coût d'entraînement effondré

Scores BLEU

BLEU · EN → DE · WMT 2014



ÉCHELLE LINÉAIRE · BASE 20

28.4 en $EN \rightarrow DE$ et **41.8** en $EN \rightarrow FR$: état de l'art · source : Vaswani et al. 2017, table 2 · échelle tronquée à 20.

Coût d'entraînement

MODÈLE	EN-DE	EN-FR	FLOPS (EN-FR)
GNMT + RL	24.6	39.9	$1.4 \cdot 10^{20}$
ConvS2S	25.2	40.5	$1.5 \cdot 10^{20}$
Transformer base	27.3	38.1	$3.3 \cdot 10^{18}$
Transformer big	28.4	41.8	$2.3 \cdot 10^{19}$

*base : **12 h** sur 8 GPU P100 · big : **3,5 jours** · $\approx 10\times$ moins de FLOPs que les SOTA.*


PARTIE 4

Impact



BERT, GPT, et l'ère des grands modèles de langage


BERT & GPT



2018 : **BERT** (encodeur seul) et **GPT** (décodeur seul) · le substrat commun du NLP.

L'ère des LLM


PARAMÈTRES · ÉCHELLE LOGARITHMIQUE



213 M $\rightarrow$ 340 M $\rightarrow$ **175 B** $\rightarrow \sim 10^{12}$: trois ordres de grandeur en six ans.

Limites du papier

COÛT MÉMOIRE / CALCUL DE L'ATTENTION



Coût **quadratique** en n · contexte borné · évalué surtout en traduction.

Merci.



Questions & discussion

arXiv:1706.03762 · NeurIPS 2017

