


Attention Is All You Need


Vaswani, Shazeer, Parmar, Uszkoreit, Jones, Gomez, Kaiser,
Polosukhin

Google Brain · Google Research · University of Toronto · NeurIPS 2017



Les limites des RNN & LSTM

- **Calcul séquentiel** : l'état h_t dépend de h_{t-1} : aucune parallélisation dans la séquence.
- **Dépendances longues** : le signal se dilue sur de grandes distances.
- **Coût croissant** : temps et mémoire suivent la longueur des phrases.
- **Convolutions** (ByteNet, ConvS2S) : atténuent, sans supprimer le problème.




RÉCURRENCE : CHAQUE ÉTAT ATTEND LE PRÉCÉDENT

Le traitement séquentiel

- **$O(n)$ opérations séquentielles** : chaque état attend le précédent.
- **Chemin long** : relier deux mots distants coûte $O(n)$ étapes.
- **Gradient fragile** : plus le chemin est long, plus les dépendances sont dures à apprendre.


Récurrent

4 sauts



Self-attention

1 saut



TOUTE PAIRE DE MOTS : CONNEXION DIRECTE

Rompre avec la récurrence

- **GPU sous-exploités** : pas de parallélisme à l'intérieur d'une séquence.
- **L'idée clé** : remplacer la récurrence par l'**attention** : un chemin $O(1)$ entre toute paire de mots.
- « **Attention Is All You Need** » : plus de récurrence, plus de convolution.


TYPE DE COUCHE	OP. SÉQUENTIELLES	CHEMIN MAX
Récurrent	$O(n)$	$O(n)$
Convolution	$O(1)$	$O(\log_k n)$
Self-attention	$O(1)$	$O(1)$

n = longueur de séquence · k = largeur du noyau

SECTION 01


L'architecture Transformer

- Encodeur & décodeur
- Self-attention
- Multi-head




Encodeur & Décodeur

- **Encodeur** : pile de $N = 6$ couches identiques.
- **Décodeur** : $N = 6$ couches, self-attention masquée.
- **Pont** : le décodeur lit la sortie de l'encodeur (K, V).
- **Dimensions** : $d_{\text{model}} = 512 \cdot d_{\text{ff}} = 2048$.




Connexion résiduelle

- **Chaque sous-couche** : $\text{LayerNorm}(x + \text{Sublayer}(x))$.
- **Le bypass** : le signal d'origine circule sans obstacle.
- **Effet** : des piles profondes qui s'entraînent sans dégradation.
- **Partout** : les 6 couches de l'encodeur et du décodeur.



Query, Key, Value

- **Trois projections** : chaque mot devient une Query, une Key et une Value.
- **Score** : compatibilité Query · Key entre tous les mots.
- **Poids** : softmax des scores → somme pondérée des Values.



La formule de l'attention


$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V$$

- $Q \cdot K^{\top}$: similarité entre chaque paire de positions.
- **softmax** : normalise chaque ligne en distribution de poids.
- $\cdot V$: chaque sortie mélange toute la séquence.

MÉCANISME

Scaled dot-product


- **Division par $\sqrt{d_k}$** : évite des produits scalaires trop grands.
- **Sans mise à l'échelle** : le softmax sature, les gradients s'évanouissent.
- **Masque optionnel** : dans le décodeur, bloque l'accès au futur.



MÉCANISME

Multi-head attention

- $h = 8$ têtes d'attention calculées en parallèle.
- $d_k = d_v = 64$: soit d_{model} / h .
- Chaque tête apprend un sous-espace de relations différent.
- Concaténation $\rightarrow$ projection linéaire finale.




Positional encoding

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

- **Sans récurrence** : l'ordre doit être injecté explicitement.
- **Sinusoïdes** ajoutées aux embeddings, longueurs d'onde en progression géométrique.


DIMENSIONS À FRÉQUENCES CROISSANTES



SECTION 02

Résultats

- WMT 2014
- BLEU 28.4 & 41.8
- Coût d'entraînement



RÉSULTATS · WMT 2014

Scores BLEU


28.4 41.8

EN → DE

EN → FR

- 28.4 en EN → DE : nouvel état de l'art, plus de +2 BLEU.
- 41.8 en EN → FR : meilleur modèle unique publié.
- Surpasse même les ensembles antérieurs.

BLEU · EN → DE · WMT 2014



ÉCHELLE LINÉAIRE · BASE 20

Coût d'entraînement

- Base : 12 heures sur 8 GPU P100.
- Big : 3,5 jours sur 8 GPU P100.
- $\sim 10\times$ moins de **FLOPs** que les SOTA précédents, à qualité supérieure.


MODÈLE	EN-DE	EN-FR	FLOPS (EN-FR)
GNMT + RL	24.6	39.9	$1.4 \cdot 10^{20}$
ConvS2S	25.2	40.5	$1.5 \cdot 10^{20}$
Transformer base	27.3	38.1	$3.3 \cdot 10^{18}$
Transformer big	28.4	41.8	$2.3 \cdot 10^{19}$

Meilleur BLEU pour un coût d'entraînement inférieur d'un ordre de grandeur.

SECTION 03

Impact


- BERT
- GPT
- L'ère des LLM



IMPACT · 1/2

Héritage : BERT & GPT


- 2018 · GPT : décodeur seul, pré-entraînement génératif.
- 2018 · BERT : encodeur seul, masquage bidirectionnel.
- Le Transformer devient le **substrat commun** du NLP.



L'ère des LLM

- Passage à l'échelle : GPT-2/3, T5, PaLM, Claude...
- Au-delà du texte : Vision Transformer (ViT), audio, multimodal.
- Scaling laws : plus de données et de calcul → capacités émergentes.
- La quasi-totalité des LLM reposent sur cette architecture.


PARAMÈTRES · ÉCHELLE LOGARITHMIQUE



REGARD CRITIQUE

Limites du papier

- **Attention en $O(n^2)$** : coût quadratique en longueur de séquence.
- **Contexte borné** : la fenêtre reste limitée en pratique.
- **Données & calcul massifs** : nécessaires pour bien performer.
- **Évaluation étroite** : centrée sur la traduction automatique.



FIN

Merci.

Questions & discussion

arXiv:1706.03762 · NeurIPS 2017

