

NEURIPS 2017 · arXiv:1706.03762

Attention Is All You Need

VASWANI · SHAZEER · PARMAR · USZKOREIT · JONES · GOMEZ · KAISER · POLOSUKHIN

GOOGLE BRAIN / GOOGLE RESEARCH / UNIV. OF TORONTO

ATTENTIVE CARTOGRAPHY

FIG. 00 — SELF-ATTENTION AS FIELD





PLATE I

Les limites des RNN & LSTM

- **Calcul séquentiel** — l'état h_t dépend de h_{t-1} , la parallélisation intra-séquence est impossible.
- **Dépendances longues** — le signal se dilue sur de grandes distances.
- **Coût croissant** — temps et mémoire augmentent avec la longueur des phrases.
- **Convolutions** (ByteNet, ConvS2S) — atténuent, mais le chemin reste proportionnel à la distance.





RÉCURRENCE : UN PAS APRÈS L'AUTRE

LE PROBLÈME · 1/2

Le traitement séquentiel

- **$O(n)$ opérations séquentielles** — chaque état attend le précédent.
- **Chemin long** — relier deux mots distants coûte $O(n)$ étapes.
- **Gradient fragile** — plus le chemin est long, plus l'apprentissage des dépendances est difficile.

LONGUEUR DU CHEMIN D'INFORMATION



Rompre avec la récurrence

- **GPU sous-exploités** — pas de parallélisme à l'intérieur d'une séquence.
- **L'idée clé** — remplacer la récurrence par l'**attention** : un chemin $O(1)$ entre toute paire de mots.
- **« Attention Is All You Need »** — plus de récurrence, plus de convolution.

TYPE DE COUCHE	OP. SÉQUENTIELLES	CHEMIN MAX
Récurrent	$O(n)$	$O(n)$
Convolution	$O(1)$	$O(\log_k n)$
Self-attention	$O(1)$	$O(1)$

n = longueur de séquence · k = largeur du noyau

ATTENTIVE CARTOGRAPHY

SECTION 01

L'architecture Transformer

ENCODER · DECODER · ATTENTION





PLATE II

Encodeur — Décodeur


- **Encodeur** — une pile de **N = 6** couches identiques.
- **Décodeur** — **N = 6** couches, avec masquage causal.
- **Chaque sous-couche** — connexion résiduelle + normalisation.
- **Dimensions** — $d_{\text{model}} = 512$, FFN interne $d_{\text{ff}} = 2048$.



ARCHITECTURE · UNE COUCHE

Sous-couches & résiduel


- **Encodeur** — self-attention multi-tête, puis FFN position-wise.
- **Décodeur** — self-attention masquée, attention encodeur-décodeur, puis FFN.
- **Résiduel** — chaque sous-couche : $\text{LayerNorm}(x + \text{Sublayer}(x))$.
- **Sortie** — Linéaire + Softmax → probabilités des mots.



SELF-ATTENTION · 1/2

Query, Key, Value

- **Trois projections** — chaque mot devient une Query, une Key et une Value.
- **Score** — compatibilité Query · Key entre tous les mots.
- **Poids** — softmax des scores → somme pondérée des Values.



La formule de l'attention


$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{Q K^T}{\sqrt{d_k}} \right) V$$

- $Q \cdot K^T$ — matrice de similarité entre chaque paire de positions ($n \times n$).
- **softmax** — normalise chaque ligne en une distribution de poids.
- $\cdot V$ — chaque sortie est un mélange contextuel de toute la séquence.

MÉCANISME

Scaled dot-product


- **Division par $\sqrt{d_k}$** — évite des produits scalaires trop grands.
- **Sans mise à l'échelle** — le softmax sature, les gradients deviennent minuscules.
- **Masquage optionnel** — dans le décodeur, bloque l'accès au futur.



MÉCANISME

Multi-head attention

- $h = 8$ têtes d'attention calculées en parallèle.
- $d_k = d_v = 64$ – soit d_{model}/h .
- Chaque tête apprend un sous-espace de relations différent.
- Concaténation → projection linéaire finale.



ORDRE DES MOTS


Positional encoding

$$PE_{(pos, 2i)} = \sin\left(pos / 10000^{2i/d}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(pos / 10000^{2i/d}\right)$$

- **Sans récurrence** — il faut injecter explicitement l'ordre.
- **Sinusoïdes** ajoutées aux embeddings, longueurs d'onde en progression géométrique.

DIMENSIONS À FRÉQUENCES CROISSANTES



ATTENTIVE CARTOGRAPHY

SECTION 02

Résultats

WMT 2014 · BLEU · COÛT D'ENTRAÎNEMENT

WMT 2014 · BLEU

PLATE III

RÉSULTATS · WMT 2014

Scores BLEU


28.4 41.8

EN → DE

EN → FR

- **EN → DE : 28.4** — nouvel état de l'art, plus de +2 BLEU.
- **EN → FR : 41.8** — meilleur modèle unique publié.
- Surpasse même les **ensembles** antérieurs.

BLEU · EN → DE (WMT 2014)



RÉSULTATS · EFFICACITÉ

Coût d'entraînement

- **Base** — 12 heures sur 8 GPU P100.
- **Big** — 3,5 jours sur 8 GPU P100.
- **FLOPs** bien inférieurs aux SOTA précédents, à qualité supérieure.


MODÈLE	EN-DE	EN-FR	COÛT (FLOPS)
GNMT + RL	24.6	39.9	$1.4 \cdot 10^{20}$
ConvS2S	25.2	40.5	$1.5 \cdot 10^{20}$
Transformer base	27.3	38.1	$3.3 \cdot 10^{18}$
Transformer big	28.4	41.8	$2.3 \cdot 10^{19}$

Meilleur BLEU pour un coût d'entraînement ~1 ordre de grandeur plus faible.

SECTION 03

Impact


BERT · GPT · L'ÈRE DES LLM



IMPACT · 1/2

Héritage : BERT & GPT

- 2018 — GPT — décodeur seul, pré-entraînement génératif.
- 2018 — BERT — encodeur seul, masquage bidirectionnel.
- Le Transformer devient le **substrat commun** du NLP.




L'ÈRE DES LLM

L'ère des LLM

- **Passage à l'échelle** — GPT-2/3, T5, PaLM, Claude...
- **Au-delà du texte** — Vision Transformer (ViT), audio, multimodal.
- **Scaling laws** — plus de données et de calcul → capacités émergentes.
- Aujourd'hui, **la quasi-totalité des LLM** reposent sur le Transformer.


CROISSANCE DES PARAMÈTRES (LOG)




REGARD CRITIQUE

Limites du papier

- **Attention en $O(n^2)$** – coût quadratique avec la longueur de séquence.
- **Contexte borné** – la fenêtre reste limitée en pratique.
- **Données & calcul massifs** – nécessaires pour de bonnes performances.
- **Évaluation étroite** – centrée sur la traduction automatique.



ATTENTIVE CARTOGRAPHY



Merci

ATTENTION IS ALL YOU NEED · VASWANI ET AL. 2017

PLATE V — FIN